FUTURE TECH LEADERS BRASIL
Space Tech Bootcamp 2026

Submissão da Proposta

Título: Do pixel à trajetória: contexto espacial e CMAP na classificação de trajetórias de cobertura na Amazônia
Candidato: Vinícius D'Lucas Bezerra e Queiroz - vinicius.dlucas@gmail.com
Repositório GitHub: https://github.com/vdlucas-queiroz/CMAP_FTL.git

1. Ideia do Projeto

Problema. A sucessão de classes de cobertura da terra ao longo do tempo, também chamada de Trajetória de Cobertura, costuma ser obtidas por comparação pós-classificação: cada imagem é classificada à parte e os resultados, empilhados. Os erros de classificação em cada data se somam e geram transições de classes que podem ser impossíveis, ao longo do tempo.

CMAP. O classificador de Máximo a Posteriori Composto (CMAP), proposto por Reis et al. (2020), classifica a trajetória inteira: escolhe a sequência de classes que maximiza o produto das probabilidades condicionais de cada data pela probabilidade *a priori* da trajetória, dada por uma matriz de transições, que zera a probabilidade das trajetórias impossíveis. Entre suas vantagens, o CMAP: retorna apenas trajetórias válidas; exige amostras de classes por data, e não amostras de trajetórias, mais difíceis de coletar; incorpora de forma simples o conhecimento sobre a dinâmica da paisagem; aceita séries esparsas, dados multissensor e probabilidades de qualquer classificador. As aplicações conhecidas do CMAP usaram apenas modelos estatísticos paramétricos para descrever as classes (Reis et al., 2020; Queiroz, 2024). O uso de probabilidades de classificadores baseados em aprendizado de máquina, capazes de explorar o contexto espacial, ainda não foi investigado.

Tarefa e objetivo. Treinar uma rede neural convolucional (CNN) com a série TM/Landsat 5 de 2005 a 2010 e usar suas probabilidades no CMAP, comparando-a a um classificador paramétrico (Máxima Verossimilhança Gaussiana, MaxVer) e a um não paramétrico (Random Forest, RF). Além de separar Floresta Primária de Vegetação Secundária, o projeto também busca marcar as trajetórias que possuem desmatamento. Como o CMAP não admite o retorno à Floresta Primária, cada desmatamento é registrado uma única vez.

Pergunta: o contexto espacial da CNN melhora, no CMAP, a acurácia das trajetórias e a detecção do desmatamento? O produto une Deep Learning, séries temporais e mapas de trajetórias e de desmatamento.

2. Relevância para os ODS e para o ecossistema espacial

O projeto se relaciona sobretudo ao **ODS 15 (Vida terrestre)**, meta 15.2: deter o desmatamento e restaurar florestas degradadas. Trajetórias consistentes distinguem desmatamento e regeneração e permitem estimar a idade da vegetação secundária, o que interessa também ao **ODS 13 (Ação climática)**, pelo papel da regeneração no balanço de carbono. A área de estudo, em Belterra (PA), junto à BR-163 e à Floresta Nacional do Tapajós, é um mosaico de floresta, pasto, agricultura e vegetação secundária.

No ecossistema espacial, o projeto usa o acervo gratuito Landsat e uma metodologia desenvolvida pelo Laboratório de Investigação em Sistemas Socioambientais (LISS) do INPE. Sua contribuição é verificar se classificadores de Deep Learning, hoje dominantes no contexto de classificação de imagens, geram probabilidades adequadas a métodos multitemporais como o CMAP, reduzindo erros na classificação de trajetórias na Amazônia.

3. Exemplos de Literatura

- **Reis et al. (2020)** propuseram e avaliaram o CMAP na série Landsat 5/TM de Belterra (2005–2010): além de eliminar as trajetórias inválidas, ele obteve Kappa e acurácia global maiores que o MaxVer. Com as mesmas imagens e amostras, é a base e a referência de comparação deste projeto.
- **Queiroz (2024)** aplicou o CMAP a séries multissensor (Landsat 5/TM e ALOS/PALSAR), com distribuições próprias para dados SAR. Ambos os trabalhos usam apenas modelos paramétricos; o uso de probabilidades de aprendizado profundo no CMAP ainda não foi avaliado, e essa é a lacuna que o projeto aborda.
- **Kussul et al. (2017)** mostraram que CNNs superam redes *perceptron* multicamadas na classificação de cobertura da terra e de culturas com Landsat-8 e Sentinel-1, o que motiva seu uso em dados Landsat.

- **Guo et al. (2017)** mostraram que redes neurais modernas tendem a ser superconfiantes e propuseram o *temperature scaling* para calibrar suas probabilidades, que o CMAP usa diretamente.

4. Descrição dos Dados

Imagens. Seis cenas TM/Landsat-5, uma por ano (01/07/2005, 21/08/2006, 21/06/2007, 23/06/2008, 12/07/2009 e 29/06/2010), as mesmas do Caso de Estudo 1 do trabalho de Reis et al. (2020), obtidas no USGS/EROS na Collection 2, nível 2 (reflectância de superfície), o que torna as datas mais comparáveis radiometricamente.

Amostras de referência. Polígonos rotulados por data, coletados com apoio de trabalhos de campo (2009, 2010 e 2013), mapas do TerraClass e interpretação visual, e divididos aleatoriamente em treino e teste (Reis et al., 2020). A legenda possui 6 classes de cobertura da terra: Solo Exposto, Agricultura, Pasto, Vegetação Secundária Inicial, Vegetação Secundária Desenvolvida e Floresta Primária.

Acesso. As imagens são públicas e gratuitas (USGS/EarthExplorer). As amostras, produzidas pelo grupo de pesquisa de Reis et al. (2020) – Laboratório de Investigação de Sistemas Socioambientais do INPE (LiSS) – são usadas com autorização. Os dados utilizados permitirão a comparação com resultados de trabalhos anteriores.

Pré-processamento (ETL):

1. Recorte, fatores de escala da Collection 2 e máscara de nuvem e sombra (banda QA_PIXEL).
2. Seleção de bandas utilizando a distância de Jeffries-Matusita;
3. Padronização das bandas por data, para reduzir diferenças radiométricas entre as cenas.
4. Divisão das amostras em treino validação e teste;
5. Extração de *patches* centrados nos pixels amostrados de cada ano e classe.

5. Metodologia

Abordagem: Deep Learning (CNN). Na legenda descrita anteriormente, as classes Floresta Primária e Vegetação Secundária concentram a maior parte das confusões e das transições inválidas na classificação pixel a pixel (Reis et al., 2020). A textura e o contexto espacial local podem ajudar a separá-las, e a CNN aprende esse contexto espacial diretamente dos *patches*, o que MaxVer e RF não fazem. Como o conjunto amostral é pequeno, a rede será rasa, e não uma arquitetura profunda pré-treinada.

1. **CNN (PyTorch):** duas camadas convolucionais 3 × 3 (32 e 64 filtros) com *batch normalization*, *dropout* e *global average pooling*, perda ponderada por classe e *data augmentation* (espelhamento e rotação).
2. **Treino conjunto das seis datas** em uma única rede, para compensar o número reduzido de polígonos por data.
3. **Calibração** por *temperature scaling* (Guo et al., 2017) no conjunto de validação.
4. **Classificadores de comparação:** MaxVer Gaussiano multivariado, como no CMAP original (Reis et al., 2020), e RF, com as mesmas bandas e a mesma divisão dos dados.
5. **CMAP:** as probabilidades geradas por CNN, RF e MaxVer entram no CMAP com a matriz de validade de transições produzida em Reis et al. (2020).
6. **Marcação de desmatamento:** a passagem de Floresta para uma classe não florestal é marcada como desmatamento no ano correspondente; supressões de vegetação secundária são registradas à parte.
7. **Avaliação:** acurácia global, e acurácias do produtor (*recall*) e do usuário (*precision*) por classe e data; qualidade das probabilidades; proporção de pixels em trajetórias inválidas na pós-classificação e discordância em relação ao CMAP.
8. **Produto final:** mapas de trajetórias de cobertura e do ano de desmatamento (2005–2010) para cada classificador, publicados em uma página no GitHub Pages; notebooks com o código aberto no GitHub;

Limitações previstas. O número reduzido de amostras nas classes minoritárias pode ampliar os intervalos de confiança e instabilizar o treino da CNN, e, além disso a autocorrelação espacial entre treino e teste. O treino conjunto de amostras em datas diferentes supõe datas radiometricamente comparáveis, embora as cenas variem de junho a agosto. Como só a CNN usa contexto espacial, a comparação mede justamente o efeito desse contexto, e um resultado negativo também será informativo.

Referências

GUO, C. et al. On calibration of modern neural networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 34., 2017. **Proceedings of Machine Learning Research**, v. 70, p. 1321–1330, 2017.

KUSSUL, N. et al. Deep learning classification of land cover and crop types using remote sensing data. **IEEE Geoscience and Remote Sensing Letters**, v. 14, n. 5, p. 778–782, 2017. DOI: 10.1109/LGRS.2017.2681128.

PLOTON, P. et al. Spatial validation reveals poor predictive performance of large-scale ecological mapping models. **Nature Communications**, v. 11, 2020. DOI: 10.1038/s41467-020-18321-y.

QUEIROZ, V. D. B. **Classificação de trajetórias de cobertura da terra utilizando uma abordagem de máximo a posteriori composto em imagens de multissensores**. 2024. Dissertação (Mestrado) – INPE, São José dos Campos, 2024.

REIS, M. S. et al. Avoiding invalid transitions in land cover trajectory classification with a compound maximum a posteriori approach. **IEEE Access**, v. 8, p. 98787–98799, 2020. DOI: 10.1109/ACCESS.2020.2997019.